

## Invarianza per Trasf.<sup>le</sup> del parametro

$$L(x_1 \dots x_n; \theta)$$

Supp.<sup>mo</sup> di voler stimare non  $\theta$ , ma una sua funzione assegnata  $\tau(\theta) \Rightarrow$  stima di  $\tau$

Se  $\tau$  è: monotona  
supp.<sup>te</sup> smooth (derivabile almeno 2 volte)

Riparametrizzo  $L$  come f.<sup>le</sup> di  $\tau$ :  $L = L(\tau)$

$$\left. \frac{d \ln L}{d\tau} \right|_{\hat{\tau}} = 0$$

$$\left. \frac{d^2 \ln L}{d\tau^2} \right|_{\hat{\tau}} < 0$$

Ma:  $\frac{d \ln L}{d \tau} = \frac{d \ln L}{d \theta} \frac{d \theta}{d \tau} = \frac{\frac{d \ln L}{d \theta}}{\frac{d \tau}{d \theta}}$

$$\frac{d \ln L}{d \tau} \Big|_{\hat{\tau}} = 0 \Leftrightarrow \frac{d \ln L}{d \theta} \Big|_{\hat{\theta}} = 0$$

$\hookrightarrow \hat{\tau} = \tau(\hat{\theta})$

Insomma:  $\frac{d^2 \ln L}{d \tau^2} = \frac{d^2 \ln L}{d \theta^2} \left( \frac{d \theta}{d \tau} \right)^2 + \frac{d \ln L}{d \theta} \left( \frac{d^2 \theta}{d \tau^2} \right)$

$\hookrightarrow \text{per } \theta = \hat{\theta}$

$$\frac{d^2 \ln L}{d \tau^2} \Big|_{\hat{\tau}} = \frac{\frac{d^2 \ln L}{d \theta^2} \Big|_{\hat{\theta}}}{\left( \frac{d \tau}{d \theta} \right)^2}$$

$\Rightarrow$  se  $\hat{\theta}$  è l'estimatore ML di  $\theta$   $\hat{\tau} \equiv \tau(\hat{\theta})$  è l'estimatore ML di  $\tau$

$\nearrow$  Hanno lo stesso segno

$$E[\hat{\tau}] = E[\tau(\hat{\theta})] \neq \tau(E[\hat{\theta}])$$

$\Downarrow$

$L_p$  a meno che  $\tau$  non sia lineare in  $\theta$

In generale (per una generica f.  $\tau(\theta)$ ) la stima ML di  $\tau$  non è unbiased

### Proprietà dell'estimatore ML

- \* Invariante per trasform. del parametro
  - \* Consistenza  $\rightarrow \hat{\theta}_n$  converge in probabilità al "valore vero"  $\theta$  che vuole stimare
  - \* Efficienza
  - \* Normalità
  - \* Sufficienza
- } asintotiche  
( $n \rightarrow \infty$ )

## Stima della varianza del MLE

### \* Metodo analitico

↳ Sfrutta l'inv. per Transf.<sup>ni</sup> del parametro  
 Applicabile quando la stima di ML è effettuale  
 in maniera analitica

↳ Es. : distribuzione esponenziale

$$V_{\theta}[\hat{\theta}_n] = \frac{\theta^2}{n}$$

$$V_{\theta}[\hat{\theta}_n] = V_{\hat{\theta}_n}[\hat{\theta}_n] = \frac{\hat{\theta}_n^2}{n}$$

### \* Metodo MC

# \* Metodo basato sul Minimum Variance Bound (MVB)

$$V_{\theta} [\hat{\theta}_n] \geq \frac{(1 + \frac{d b_n}{d \theta})^2}{E_{\theta} \left[ - \frac{\partial^2 \ln L(x_1 \dots x_n; \theta)}{\partial \theta^2} \middle| \theta \right]} = \text{MVB}_n(\theta)$$

$\downarrow$  Generico estimatore di  $\theta$  basato su  $n$  misure
  $\rightarrow$  Informatione di Fisher

$$b_n(\theta) = \text{bias}$$

Nel caso unbiased, o almeno  $\frac{d b_n}{d \theta} = 0$  o trascurabile rispetto a 1:

$$\frac{1}{\text{MVB}_n(\theta)} = E_{\theta} \left[ - \frac{\partial^2 \ln L(x_1 \dots x_n; \theta)}{\partial \theta^2} \middle| \theta \right] =$$

$$\equiv - \int_{-\infty}^{+\infty} dx_1 \dots \int_{-\infty}^{+\infty} dx_n \frac{\partial^2 \ln L(x_1 \dots x_n; \theta)}{\partial \theta^2} L(x_1 \dots x_n; \theta)$$

Nel caso iid :  $L(x_1, \dots, x_n; \theta) = \prod_{i=1}^n f(x_i; \theta)$

$$\Downarrow$$

$$\ln L(x_1, \dots, x_n; \theta) = \sum_{i=1}^n \ln f(x_i; \theta)$$

$$\frac{\partial^2 \ln L}{\partial \theta^2} \Big|_{\theta} = \sum_{i=1}^n \frac{\partial^2 \ln f(x_i; \theta)}{\partial \theta^2} \Big|_{\theta}$$

Per cui:

$$\frac{1}{\text{MVB}_n(\theta)} = \int_{-\infty}^{+\infty} dx_1 \dots \int_{-\infty}^{+\infty} dx_n \left( - \sum_{i=1}^n \frac{\partial^2 \ln f(x_i; \theta)}{\partial \theta^2} \Big|_{\theta} \right) \prod_{i=1}^n f(x_i; \theta) =$$

$$= n \int_{-\infty}^{+\infty} - \frac{\partial^2 \ln f(x; \theta)}{\partial \theta^2} \Big|_{\theta} f(x; \theta) dx = \frac{n}{\text{MVB}_1(\theta)}$$

$$\Downarrow$$

$$\text{MVB}_n(\theta) = \frac{\text{MVB}_1(\theta)}{n}$$

Caso generale di più parametri ( $p > 1$ )

$$U_{ij}^{-1} = \mathbb{E}_{\underline{\theta}} \left[ - \frac{\partial^2 \ln L(x_1, \dots, x_n; \underline{\theta})}{\partial \theta_i \partial \theta_j} \bigg|_{\underline{\theta}} \right]$$

↳ Matrice di covarianza di  $\hat{\theta}_1, \dots, \hat{\theta}_p$

Anche in questo caso:

$$U_{ij}^{-1} = n \int_{-\infty}^{+\infty} \left( - \frac{\partial^2 \ln f(x; \theta)}{\partial \theta_i \partial \theta_j} \bigg|_{\theta} \right) f(x; \theta) dx$$

$$U_{ij} \propto \frac{1}{n}$$

Se  $n$  è suff. <sup>re</sup> grande :  $V_{\theta} [\hat{\theta}_n] \stackrel{\text{MLE}}{\approx} \frac{1}{E_{\theta} \left[ - \frac{\partial^2 \ln L(x_1, \dots, x_n; \theta)}{\partial \theta^2} \right]_{\theta}}$

$V_{\theta} (\hat{\theta}_n) \approx \text{MVB}_n (\theta) = \frac{\text{MVB}_1 (\theta)}{n}$   
 $\downarrow$  Inv. per Transl. <sup>si</sup> del param.

$\hat{V} [\hat{\theta}_n] \approx \text{MVB}_n (\hat{\theta}_n) = \frac{\text{MVB}_1 (\hat{\theta}_n)}{n} =$   
 $= \frac{1}{n} \frac{1}{E_{\hat{\theta}_n} \left[ - \frac{\partial^2 \ln f(x; \theta)}{\partial \theta^2} \right]_{\hat{\theta}_n}}$



$$E[\xi] \approx \frac{1}{n} \sum_{i=1}^n \xi_i$$

$$n E_{\hat{\theta}_n} \left[ - \frac{\partial^2 \ln f(x_i; \theta)}{\partial \theta^2} \Big|_{\hat{\theta}_n} \right] \approx$$

$$\approx \cancel{n} \frac{1}{\cancel{n}} \sum_{i=1}^n \underbrace{\left( - \frac{\partial^2 \ln f(x_i; \theta)}{\partial \theta^2} \Big|_{\hat{\theta}_n} \right)}_{\xi_i} =$$

$$= - \sum_{i=1}^n \frac{\partial^2 \ln f(x_i; \theta)}{\partial \theta^2} \Big|_{\hat{\theta}_n} = - \frac{\partial^2 \ln L(x_1, \dots, x_n; \theta)}{\partial \theta^2} \Big|_{\hat{\theta}_n}$$

$$V[\hat{\theta}_n] \xrightarrow{\text{MLE}} \frac{1}{- \frac{\partial^2 \ln L(x_1, \dots, x_n; \theta)}{\partial \theta^2} \Big|_{\hat{\theta}_n}}$$

\* Metodo grafico


$$\ln L(\theta) = \underbrace{\ln L(\hat{\theta})}_{\ln L_{\max}} + \cancel{\frac{\partial \ln L}{\partial \theta} \bigg|_{\hat{\theta}}} (\theta - \hat{\theta}) + \frac{1}{2} \frac{\partial^2 \ln L}{\partial \theta^2} \bigg|_{\hat{\theta}} (\theta - \hat{\theta})^2 + \dots$$

Termini trascurati  
per n suff. grande

$$\ln L(\theta) \approx \ln L_{\max} + \frac{1}{2} \frac{\partial^2 \ln L}{\partial \theta^2} \bigg|_{\hat{\theta}} (\theta - \hat{\theta})^2$$

$$\approx \ln L_{\max} - \frac{1}{2} \frac{(\theta - \hat{\theta})^2}{\widehat{V}(\hat{\theta})}$$

$$\widehat{V}[\hat{\theta}] \approx - \frac{1}{\frac{\partial^2 \ln L}{\partial \theta^2} \bigg|_{\hat{\theta}}}$$



$\mathcal{P} = 1$   
 A  $x_1 \dots x_n$  function

## Extended ML

$$X \sim f(X; \theta)$$

$x_1 \dots x_n$   $n$  misure di  $X$

$n$  realizzazione della misura di una variabile casuale  
(numero di conteggi)

Likelihood "estesa"

$$L(n, x_1 \dots x_n; \nu, \theta) = \frac{\nu^n e^{-\nu}}{n!} \prod_{i=1}^n f(x_i; \theta)$$

↳ variabile casuale Poissoniana con  $E[n] = \nu$

$$n \sim P(\nu)$$

$$P(n; \nu) = \frac{\nu^n e^{-\nu}}{n!}$$

\*1)  $\nu$  non dip. da  $\Theta$

$$\hat{\nu} : \frac{\partial \ln L}{\partial \nu} \Big|_{\hat{\nu}} = 0$$

$$\downarrow$$

$$\frac{n}{\hat{\nu}} - 1 = 0 \Rightarrow \hat{\nu} = n$$

\*2)  $\nu = \nu(\Theta)$

$$\ln L(n, x_1, x_2; \Theta) = n \ln \nu(\Theta) - \nu(\Theta) + \sum_{i=1}^n \ln f(x_i; \Theta) + \dots$$

$$= -\nu(\Theta) + \sum_{i=1}^n \ln (\nu(\Theta) f(x_i; \Theta)) + \dots$$

Verrini che  
non dip. da  $\Theta$   
 $\downarrow$

## ML con dati "binari"

$$x_1 \dots x_n \quad f(x; \theta)$$

$n_i$  = num di misure nell'i-mo bin di un istogramma  
con un range "più" al supporto di  $X$  e con  $N$  bin  
 $(x_i^{\min}, x_i^{\max}) \rightarrow$  range i-mo bin

$$\underline{n}^T = (n_1, \dots, n_N)$$

sotto l'ip che  $X \sim f(x; \theta)$  i valori di aspett. delle  $n_i$ ,  
che chiameremo  $\underline{v}^T(\theta) = (v_1(\theta), \dots, v_N(\theta))$

$$v_i(\theta) = n \int_{x_i^{\min}}^{x_i^{\max}} f(x; \theta) dx$$

$$\therefore p_i(\theta) = \int_{x_i^{\min}}^{x_i^{\max}} f(x; \theta) dx = \frac{v_i(\theta)}{n}$$

Num tot di misure :  $n = \sum_{i=1}^N n_i$

Pdf congiunta di  $n_1 \dots n_M \rightarrow$  distribuzione multinomiale  
(generalizzazione per  $M \geq 2$  della distribuzione binomiale)

$$f_{\text{conj}}(\underline{n}; \underline{v}(\theta)) = \frac{n!}{n_1! \dots n_M!} p_1^{n_1}(\theta) \dots p_M^{n_M}(\theta) =$$

$$= \frac{n!}{n_1! \dots n_M!} \left( \frac{v_1(\theta)}{n} \right)^{n_1} \dots \left( \frac{v_M(\theta)}{n} \right)^{n_M}$$

$$\ln L(n_1 \dots n_M; \theta) = \sum_{i=1}^M n_i \ln v_i(\theta) + \dots$$

↑ termini indep. da  $\theta$

# ML binomiale ed altre

$$f_{\text{cong}}(\underline{n}, \underline{m}; \nu, \theta) = \frac{\nu^N e^{-\nu}}{n!} \frac{n!}{m_1! \dots m_M!} P_1^{m_1}(\theta) \dots P_M^{m_M}(\theta) =$$

$\downarrow$   
 $\hookrightarrow \underline{m}^T = (m_1 \dots m_M)$

Num. di conteggi (var. poissoniana con  $E[x] = \nu$ )

$$P_i = \frac{\nu_i}{\nu} \quad e^{-\sum_{i=1}^M \nu_i} = \frac{N}{1} e^{-\nu}$$

$$= \frac{\cancel{\nu^N} e^{-\cancel{\nu}}}{n!} \frac{\cancel{n!}}{m_1! \dots m_M!} \left( \frac{\nu_1(\theta)}{\nu} \right)^{m_1} \dots \left( \frac{\nu_M(\theta)}{\nu} \right)^{m_M} =$$

$$\nu = \sum_{i=1}^M \nu_i$$

$$n = \sum_{i=1}^M m_i$$

$$= \frac{N}{1} \frac{e^{-\nu} \nu_i^{m_i}}{m_i!} = L(\nu_i; m_i)$$

serve per test hypo



$$\ln L(\underline{n}, \underline{m}; \nu, \theta) = -\nu + \sum_{i=1}^N n_i \ln \nu; (\nu, \theta) + \dots$$

⚡  
Terms indep. of  $\theta$