

Test d'ipotesi

Laboratorio di Metodi Computazionali e Statistici (2023/2024)

Roberta Cardinale e Fabrizio Parodi

Dipartimento di Fisica - Università di Genova

18 Dicembre 2023

Test statistici: introduzione

- strumento per fare affermazioni sulla validità di un modello basandosi su una serie di dati raccolti (oppure tra due modelli in competizione, verificare quale è più consistente con i dati)
- strumento per classificazione di eventi (selezionare eventi) provenienti da due diversi tipi (tecniche multivariate)

Test statistici

- Supponiamo di aver effettuato un esperimento/misura, assumiamo che i dati siano un set di N osservabili (caratteristiche dell'esperimento/misura)

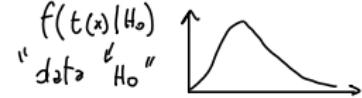
$$\mathbf{x} = (x_1, \dots x_N)$$

- \mathbf{x} seguono una distribuzione di probabilità congiunta
- Ipotesi: specifica la distribuzione di probabilità dei dati (\mathbf{x})
- L'obiettivo è di effettuare una qualche affermazione basandosi sui dati osservati \mathbf{x} sulla validità di una possibile ipotesi
- Il test può essere effettuato su una grandezza osservata nell'esperimento o su qualsiasi funzione di una o più grandezze osservate nell'esperimento
- Spesso si costruisce una variabile $t(\mathbf{x})$ dall'insieme delle osservabili/misure detta "statistica di test"
- Statistica di test: è una variabile funzione dei dati che fornisce un metodo per fare un test delle ipotesi (che ha cioè un potere discriminante tra diverse ipotesi)

Ipotesi Se t cade in W $\alpha = 1\%$ rigetta l'ipotesi con significanza dell'1%

- Vogliamo determinare la validità di una ipotesi sulla base del $t(x)$ osservato (che dipende solo dai dati): possiamo rigettare l'ipotesi dai dati che abbiamo?
- La statistica $t(x)$ avrà una distribuzione di probabilità per l'ipotesi H_0 (ipotesi nulla): $f(t(x)|H_0)$ quella da verificare
- Un test di ipotesi H_0 è definito specificando una regione critica W (detta anche regione di rigetto dell'ipotesi H_0) dello spazio dei dati S , tale che, assumendo H_0 sia corretta, la probabilità di osservare t in tale regione sia uguale o minore di α :

$$P(t \in W|H_0) \leq \alpha$$



- α è la significanza del test (ed è un valore scelto da noi).
- Se il valore ottenuto dai dati di t è in W , l'ipotesi H_0 è rigettata.
- La regione complementare a W è detta regione di accettanza (non possiamo rigettare l'ipotesi H_0). \rightarrow ~~NB~~ Non sto dicendo che H_0 è vera



α (piccolo che scelgo io)

$\alpha = 1\%$
$\alpha = 5\%$

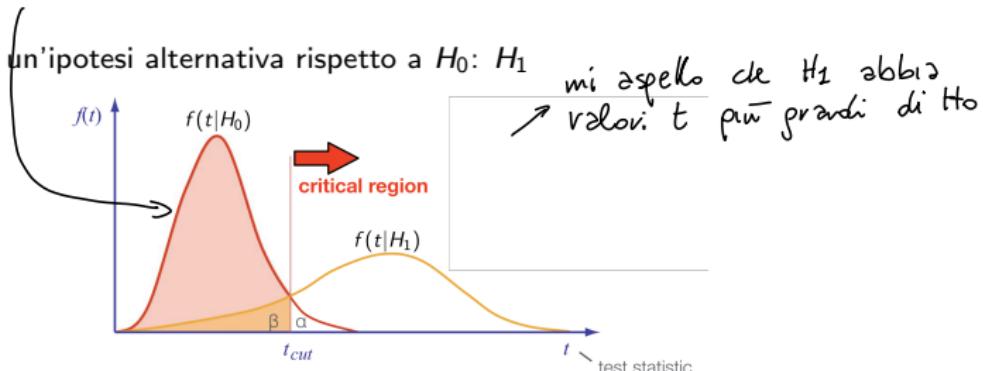
di solito

Errori di Tipo I e Tipo II

H_0 = nulla H_1 = alternativa

test statistico

- Consideriamo un'ipotesi alternativa rispetto a H_0 : H_1



- Errore di tipo I: rigettare l'ipotesi H_0 se è vera. La massima probabilità per questo errore è

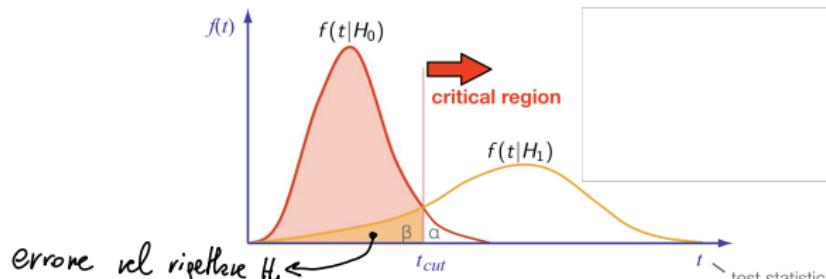
$$P(t \in W | H_0) \leq \alpha \quad \text{dove} \quad \alpha = \int_{t_{cut}}^{\infty} f(t|H_0) dt$$

α è il livello di significanza del test, ed è definito come la probabilità di t di essere nella regione W in cui rigetto H_0 , quando H_0 è vera

Non è d'uso che se t in W H_0 sia davvero da rigettare
 H_0 vera ma lo rigozzo, perché ho un errore al

Errori di Tipo I e Tipo II

- Consideriamo un'ipotesi alternativa rispetto a H_0 : H_1



- Errore di tipo II: rigettare l'ipotesi alternativa H_1 se è vera

$$P(t \in S - W | H_1) \leq \beta \quad \text{dove} \quad \beta = \int_{-\infty}^{t_{cut}} f(t|H_1) dt$$

β è la probabilità che t cada nella regione di accettanza per H_0 se H_1 è vera

- L'utilità di un test dipende dalla sua capacità di discriminare l'ipotesi alternativa H_1 .
- Per misurare l'utilità di un test si usa la potenza del test definita come la probabilità $1 - \beta$ cioè la probabilità che t cada nella regione critica se H_1 è vera
 $P(t \in W | H_1) \leq 1 - \beta$ (potenza del test)
- cioè di rigettare H_0 se H_1 è vera

Errori di tipo I o II

		hp iniziale	hp alternativa
		H_0 TRUE	H_1 TRUE
$X \notin w$	ACCEPT H_0	Acceptance good $\text{Prob} = 1 - \alpha$	Contamination Error of the second kind $\text{Prob} = \beta$
$X \in w$ (critical region)	REJECT H_0	Loss Error of the first kind $\text{Prob} = \alpha$	Rejection good potenza del test $\text{Prob} = 1 - \beta$

Se considero eventi di H_0 che è in realtà evento di H_1 sto contaminando il test.

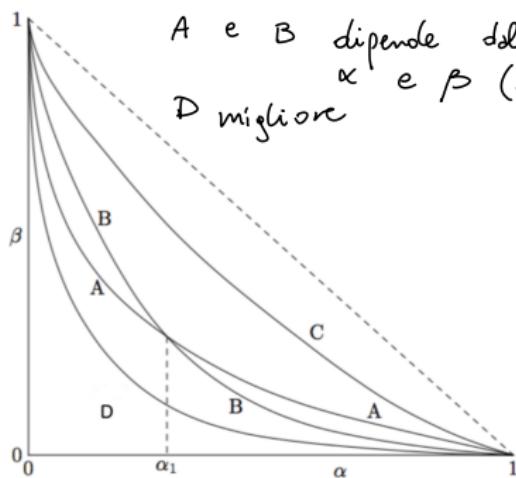
Se ho eventi di H_0 e li considero di H_1 sto perdendo dagli eventi

Scelta del test statistico (I)

- Come si effettua la scelta di un test statistico?
- Dato un esperimento/una serie di dati, posso determinare più test statistici
- Ma quale è il migliore?

c è il peggiore xk β migliore ad α fisso

*A e B dipende dal test di significanza
α e β (che sono vincolati)*



- Il miglior test è quello per cui fissato α , β sia il più piccolo possibile

Scelta del test statistico (II)

Il lemma di Neyman-Pearson afferma che in un test d'ipotesi tra due ipotesi H_0 e H_1 , la statistica di test ottimale, cioè quella che ha la potenza massima tra tutti i test (cioè quella con il più piccolo valore di β) con significatività α , la regione critica W deve essere tale che per tutti i valori x nella regione critica si ha:

$$\frac{f(x|H_1)}{f(x|H_0)} > c \quad \text{in } W \quad \circ \leq c \text{ fuori}$$

all'interno di W e $\leq c$ fuori dalla regione, dove c è una costante scelta per avere un test con un determinato livello di significanza desiderato

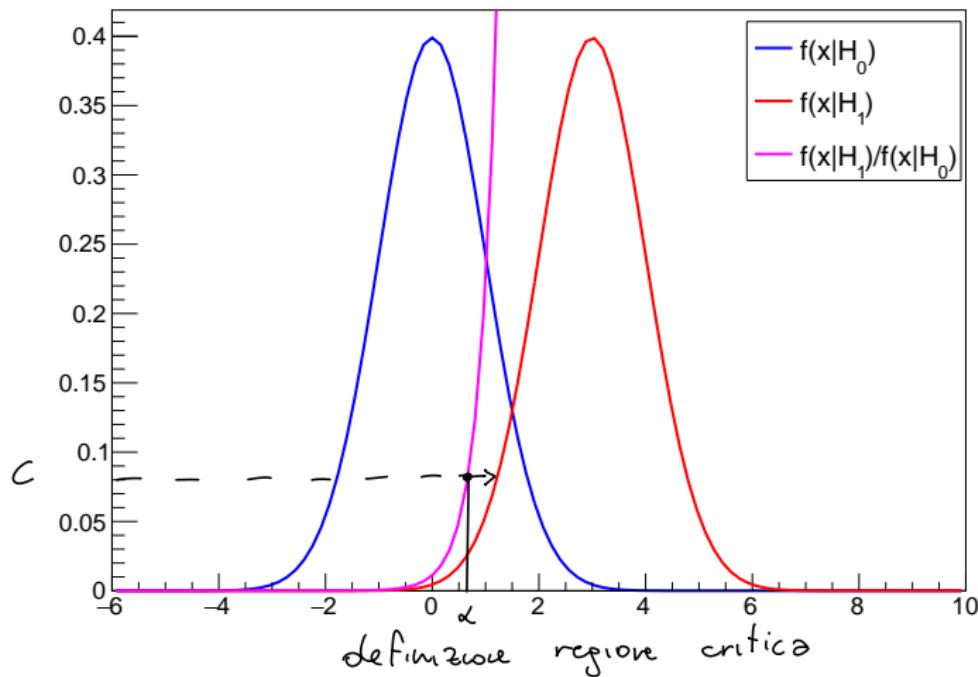
Per cui dobbiamo richiedere che per tutti i punti x nella regione critica, il rapporto delle distribuzioni di probabilità sia maggiore di una costante c dove c corrisponde al valore di taglio dato il valore di significanza α scelto

Equivalentemente a dire che il test statistico ottimale è dato da:

$$t(x) = \frac{f(x|H_1)}{f(x|H_0)}$$

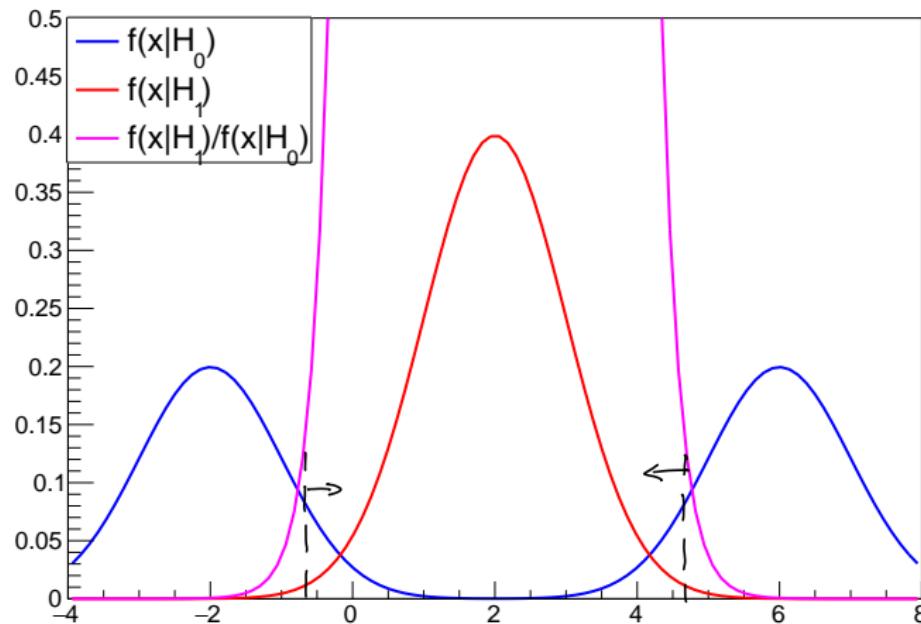
Lemma NP: esempio (I)

Lemma Neyman-Pearson



Lemma NP: esempio (II)

Lemma Neyman-Pearson



p-value

- Spesso si vuole esprimere il livello di accordo dei dati con un'ipotesi H cioè vogliamo quantificare il livello di compatibilità tra i dati ottenuti e quelli attesi secondo l'ipotesi H
- Si definisce una statistica di test $t(\mathbf{x})$
- Si ha la distribuzione della statistica di test $f(t|H)$ data l'ipotesi considerata H
- Si utilizza il p-value definito come probabilità di osservare, assumendo H vera, dati \mathbf{x} (o $t(\mathbf{x})$) che hanno minore o uguale compatibilità con H rispetto ai dati che abbiamo osservato (\mathbf{x}_{oss} o $t_{\text{oss}}(\mathbf{x})$)

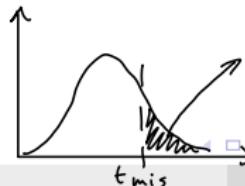
NB cerco una funzione che mi dice quanto i dati si avvicinano all'ipotesi, poi passo alla distribuzione di prob della funzione

p-value

prob di avere un t con compatibilità minore o uguale al t_{mis}

NB ottengo un valore di $t \rightarrow t_{\text{mis}}$ V set di dati

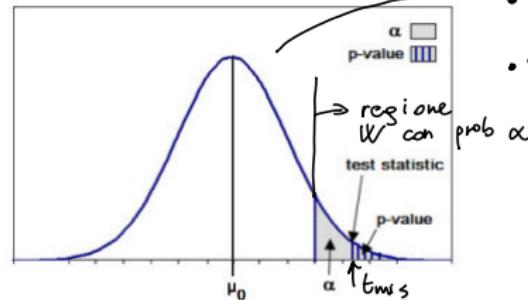
$$p = P(\mathbf{x} \in \omega \leq \mathbf{x}_{\text{oss}} | H)$$



p-value

- Si calcola dalla distribuzione della statistica di test tenendo conto dell'ipotesi considerata $f(x|H)$

$$p = \int_{x:x \geq x_{obs}} f(x|H) dx \text{ per distribuzioni continue}$$
$$p = \sum_{x:x \geq x_{obs}} f(x|H) dx \text{ per distribuzioni discrete}$$



- distribuzione aspettativa dei dati che verificano H_0 (cioè fondo segue una Poissoniana μ_0 centro)
- Se ottengo una misura che sta in W , evento non è di H_0 , rigetto H_0

$$p = \int_{t_{obs}}^{+\infty} f(t|H) dt$$

si calcolato data una misura

Decisa una significanza del test α , l'ipotesi H è rigettata se $p < \alpha$.

↓
Sielto

p-value

(in approccio bayesiano ho prob sulle hp)

Qui usiamo frequentista, bayesiano e freq convergono allo stesso risultato

- Attenzione: p non è la probabilità che H sia vera dati i dati raccolti!
- Nell'approccio frequentista: non esiste la probabilità di H ma solo la probabilità di ottenere un altro set di valori x_{ooss}
- È la probabilità di ottenere dei dati incompatibili almeno tanto quanto i dati che abbiamo se l'ipotesi è vera.
- Noi ci concentreremo solo sull'approccio frequentista

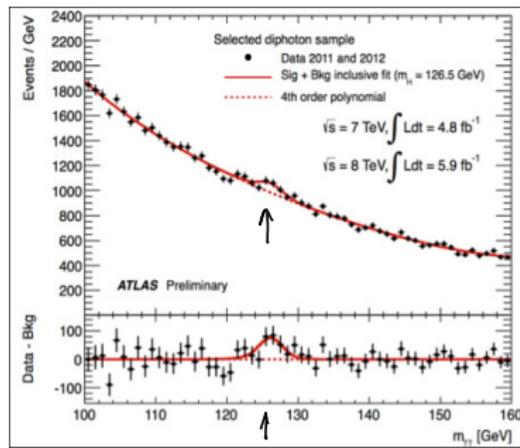
è Prob di ottenere un set di dati più estremo (meno compatibile con H_0) di quello misurato, o estremo uguale (compatibile uguale)

Se p-value piccolo vuol dire che set di dati già molto estremo

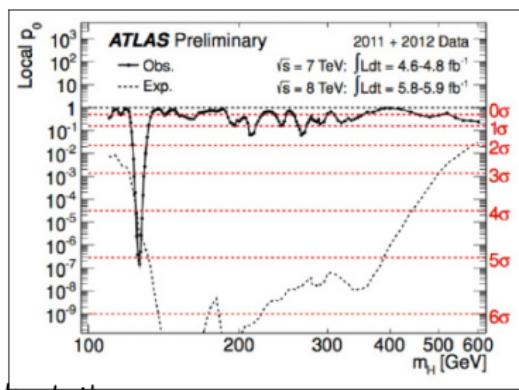
Esempio: scoperta del bosone di Higgs (ATLAS e CMS)

$H \rightarrow \gamma\gamma$ (2 fotoni) e calcolo massa invariante. Se $\gamma\gamma$ arrivano da decadimento di H decade in arranno energia in corrispondenza della massa invariante di H

Distribuzione di massa



pico in massa invariante di H



Alla scoperta del bosone di Higgs molti quotidiani hanno tradotto l'informazione (corretta) "la probabilità di una tale fluttuazione nei dati se non esiste il bosone di Higgs è 3×10^{-7} " nell'affermazione (falsa e fuorviante) "la probabilità che non esista il bosone di Higgs, osservata quella fluttuazione nei dati, è 3×10^{-7} "

Una fluttuazione dei dati (dovuta al caso) così grande ha probabilità molto bassa \Rightarrow esiste Bosone $\&$ fluttuazione generata da un nuovo fenomeno e non dal caso

p-value

- Il p-value non deve essere confuso con il livello di significanza α
 - il livello di significanza è un valore fisso scelto a priori
 - il p-value è una funzione dei dati e quindi è esso stesso una variabile aleatoria (con una data distribuzione)
- Un p-value piccolo è indice di una inconsistenza con l'ipotesi formulata
- L'ipotesi è rigettata se $p < \alpha$.

Esempio

- Supponiamo di effettuare un esperimento di conteggi
- Ci aspettiamo un certo numero di eventi b che conosciamo
- Osserviamo n eventi
- Immaginiamo di voler capire se il numero di eventi osservati è compatibile con il numero di eventi attesi b
- Nel caso avessimo non solo gli eventi non interessanti b ma anche eventi interessanti mai visti prima s ? *segna nuova ho solo 1 esperimento dare conto sia s che b*
- Contiamo solo il numero totale di eventi ($s+b$)

$$P(n|s, b) = \frac{(s+b)^n}{n!} e^{-(s+b)} \quad \text{Poissoniana di } s+b \text{ eventi}$$

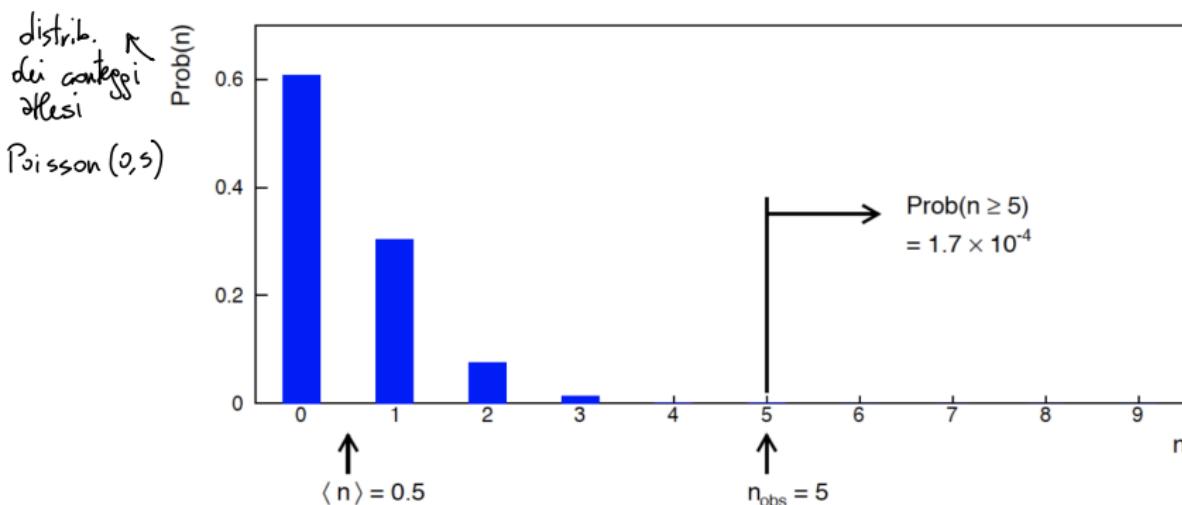
- s = numero medio di eventi interessanti *(nuovi, mai osservati oppure possono essere fluttuazioni dal val medio dei b)*
- b = numero medio di eventi non interessanti *(di cui conosco distrib. teorica)*
- Vogliamo testare l'ipotesi $H_0(s=0)$ (rigettare l'ipotesi H_0 : c'è un tipo di eventi mai visti prima)
- Testare $H_0(s \neq 0)$: intervalli di confidenza *oppure*

Esempio

n^o attesi di eventi è fluttuazione statistica
da o, s oppure nuovo evento?

- Supponiamo noto $b = 0.5$ e osserviamo $n_{\text{oss}} = 5$
- Cosa possiamo dire di H_0 ?
- Calcoliamo il p-value per $H_0(s = 0)$

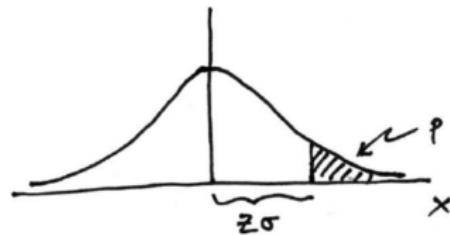
$$p = P(n \geq 5; b = 0.5, s = 0) = \sum_{n=5}^{\infty} \frac{b^n}{n!} e^{-b} = 1 - \sum_{n=0}^4 \frac{b^n}{n!} e^{-b} = 1.7 \times 10^{-4}$$



Quantile

Di quante σ mi sono spostato rispetto al medio?

- Spesso si converte il p-value in una probabilità equivalente (chiamata significanza o equivalente significanza Gaussiana o quantile)



$$p = \int_Z^\infty \frac{1}{\sqrt{2\pi}} e^{-x^2/2} dx = 1 - \Phi(Z)$$

($\bar{x}=0$ e $\sigma=1$) Gauss

$$Z = \Phi^{-1}(1 - p)$$

In ROOT

```
p = 1 - TMath::Freq(Z)
Z = TMath::NormQuantile(1-p)
```

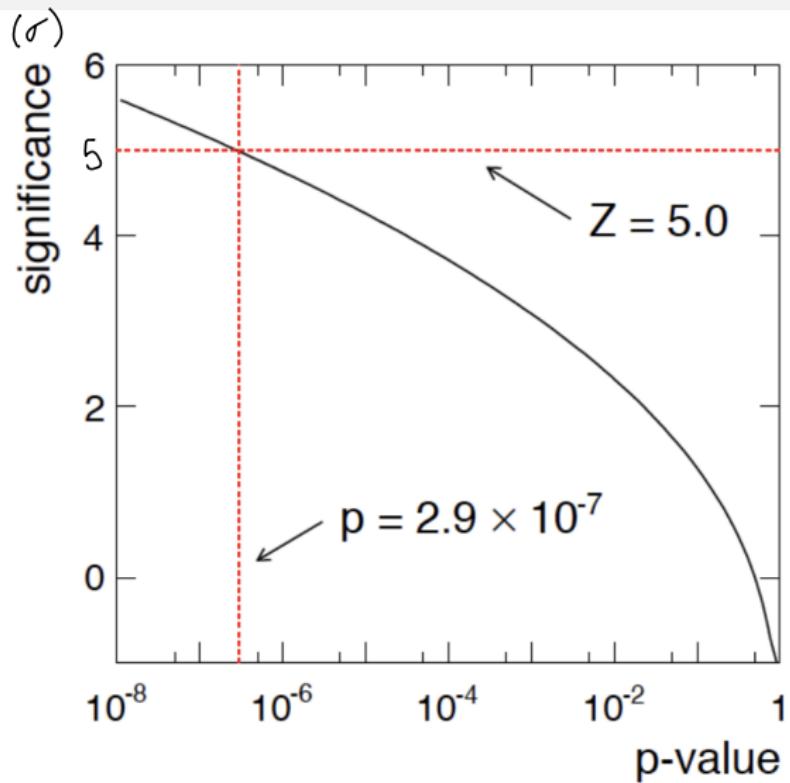
In python (scipy.stats)
cumulative density function

```
p = 1 - norm.cdf(Z) = norm.sf(Z)
Z = norm.ppf(1-p)
```

- Z è il numero di deviazioni standard che una variabile Gaussiana fluttuerebbe (in una direzione) per dare lo stesso p-value
- Per esempio Z= 5 (σ) equivale a 2.9×10^{-7}

$$Z = 2.4(1) \rightarrow 0.01 \quad (1\%)$$

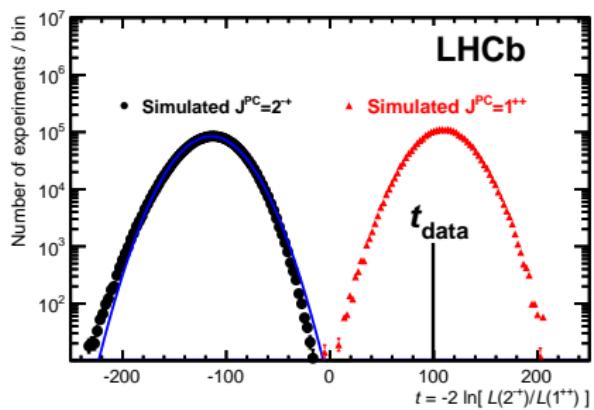
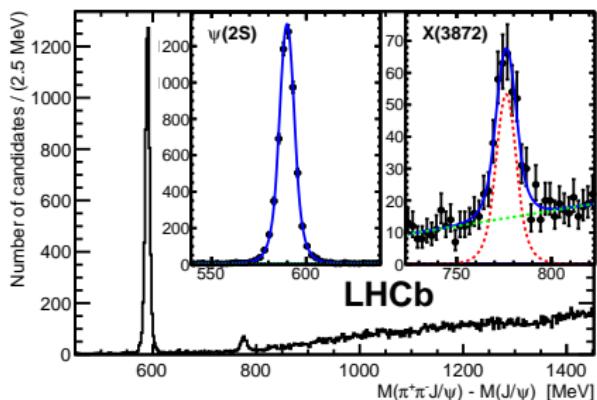
Quantile (II)



Come procede il processo di test?

- Definiamo un'ipotesi nulla H_0 e possibili ipotesi alternative
- Selezioniamo un test statistico t
- Determiniamo la distribuzione attesa per t nel caso di ipotesi nulla $f(t|H_0)$
- Scegliamo il valore di α tenendo in conto degli errori di tipo I e di tipo II e definiamo la regione critica
- Determiniamo dai dati il valore di t
- Confrontiamo se il valore di t misurato si trova nella regione critica: se è nella regione critica, rigettiamo l'ipotesi nulla, altrimenti concludiamo che non c'è evidenza per rigettare l'ipotesi nulla

Determinazione spin particella esotica



t può essere confrontato fra
compatibilità dei dati
oppure rapporto modello e dati,
Likelihood, χ^2 , ecc

Test parametrici e non-parametrici

I test di ipotesi si possono suddividere in:

- Test parametrici: riguardano ipotesi sul valore di un parametro della distribuzione (occorre assumere una distribuzione) come la media/la deviazione standard
 - Non Parametrici: riguardano il tipo di distribuzione ipotizzabile. Non richiedono la conoscenza a priori della distribuzione dei dati
 - Test di bontà del fit o detti test di bontà dell'adattamento
- ↙ *V tipi di distribuzione*

Test parametrici: il problema dei due campioni

- Vogliamo confrontare due campioni di dati e vedere se sono compatibili (se provengono dalla stessa popolazione)
- Anche se provengono dalla stessa popolazione, avranno delle differenze dovute a fluttuazioni statistiche
 - Due campioni gaussiani con σ nota, la media dei due campioni è la stessa?
 - Due campioni gaussiani con stessa (non nota) σ , la media dei due campioni è la stessa?
 - Due campioni gaussiani, σ_1 è compatible con σ_2 ?

Due gaussiane, σ nota, stessa media?

Supponiamo di avere dei campioni indipendenti (x_1, \dots, x_n) e (y_1, \dots, y_n) (Lab 1) provenienti da due popolazioni normali di varianze note σ_x^2 e σ_y^2 . Calcoliamo le medie dei due campioni \bar{x} e \bar{y} . Sono uguali?

Ci chiediamo se i due campioni hanno la stessa media oppure no? Riformulazione: $\bar{x} - \bar{y}$ è compatibile con 0? cioè la differenza tra le medie è significativa? O dipende solo da fluttuazioni casuali dovute alla dimensione dei campioni di dati?

Esempio: due misure effettuate con apparati diversi con risoluzione σ_x e σ_y

Due gaussiane, σ nota

Test a una coda destro:

$$\theta = \bar{x} - \bar{y}$$

$$\epsilon_{x-y} = \sqrt{\sigma_x^2/N_x + \sigma_y^2/N_y}$$

$$\theta_0 = 0$$

$\theta_0 = 0$ \Rightarrow diff sig > 0 statistica di test

$$H_0 = 0$$

• 10

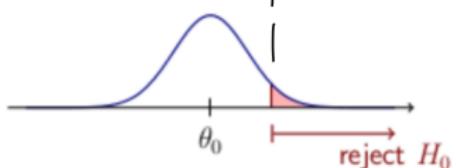
$$\theta = \theta_0 \quad \theta \geq \theta_0 \quad (\theta - \theta_0)/\epsilon$$

$$t = (\theta - \theta_0)/\epsilon = Z$$

in numero di deviazioni standard

Quanto si discosta v_d m/s
da v_d medio (contando errore)
N° di dist dal v_d medio

Caso in cui
 H_2 mi dica di
 scegliere W per $\theta > 0$



Due gaussiane, σ nota

Test a una coda sinistro:

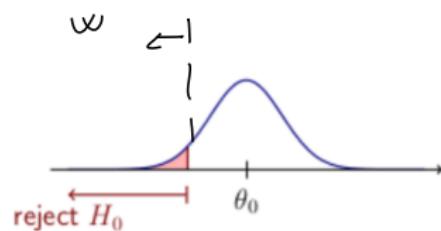
$$\theta = \bar{x} - \bar{y}$$

$$\epsilon_{x-y} = \sqrt{\sigma_x^2/N_x + \sigma_y^2/N_y}$$

$$\theta_0 = 0$$

H_0	H_1	test
$\theta = \theta_0$	$\theta < \theta_0$	$(\theta - \theta_0)/\epsilon$
$t = (\theta - \theta_0)/\epsilon = Z$		in numero di deviazioni standard

Caso in cui
 H_1 mi dice di prendere ψ
in $\theta < 0$

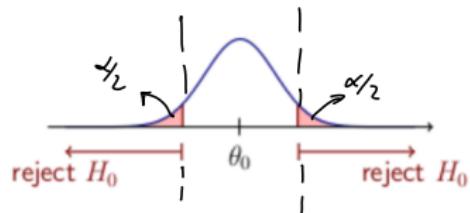


Due gaussiane, σ nota

Test a due code:

$$\theta = \bar{x} - \bar{y}, \epsilon_{x-y} = \sqrt{\sigma_x^2/N_x + \sigma_y^2/N_y}, \theta_0 = 0$$

H_0	H_1	test δ 2 code
$\theta = \theta_0$	$\theta \neq \theta_0$	$ \theta - \theta_0 /\epsilon \rightarrow$ n° σ di scostamento
$t = (\theta - \theta_0)/\epsilon = Z$		in numero di deviazioni standard



La questione si riduce al calcolo di quante σ la differenza è distante rispetto a zero. E si confronta il livello di significatività del test voluto con la tabella dell'integrale della Gaussiana.

Tipo critico del 3 σ

Due gaussiane, σ ignota, σ uguali, stessa media?

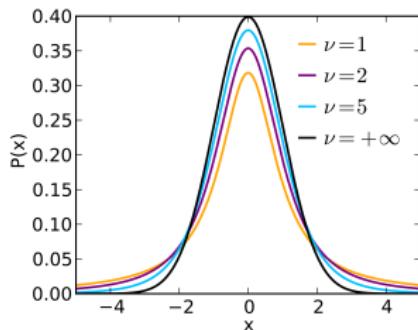
- Se non conosciamo la varianza della popolazione, possiamo stimarla con la varianza campionaria $s_x = \sqrt{\frac{\sum(x_i - \bar{x})^2}{N_x - 1}}$ e $s_y = \sqrt{\frac{\sum(y_i - \bar{y})^2}{N_y - 1}}$
- La statistica di test

$$t = \frac{\bar{x} - \bar{y}}{S \sqrt{(1/N_x) + (1/N_y)}}$$

$$\text{con } S^2 = \frac{(N_x - 1)s_x^2 + (N_y - 1)s_y^2}{N_x + N_y - 2}$$

- è distribuita secondo la distribuzione di Student con numero di gradi di libertà $n = N_x + N_y - 2$

contributo code maggiori della Gaussiana
significanza minore rispetto Gaussiana



La significanza di una deviazione tra x e y è inferiore (la distribuzione ha code più lunghe) rispetto al caso precedente.

Distribuzione di Student

- Dati n campioni casuali provenienti da una popolazione normale con valor medio μ la variabile:

$$t = \frac{\bar{x} - \mu}{\frac{s}{\sqrt{n}}}$$

dove \bar{x} =media campionaria e s = deviazione standard campionaria

- PDF della distribuzione di Student (distribuzione t) campione piccolo e dev. std. pop

$$f(t) = \frac{\Gamma(\frac{\nu+1}{2})}{\sqrt{\nu\pi}\Gamma(\frac{\nu}{2})} \left(1 + \frac{t^2}{\nu}\right)^{-(\nu+1)/2}$$

con ν =numero di gradi di libertà e Γ è la funzione Gamma.

- Si utilizza in situazioni in cui la dimensione del campione è piccola e la deviazione standard della popolazione non è nota
- Forma a campana come la Gaussiana ma con code più importanti
- Per $\nu \geq 30$: approssimabile ad una Gaussiana
- Sviluppata da uno statistico inglese William Gosset con lo pseudonimo di Student che lavorava nella fabbrica della Guinnes sviluppando metodi statistici per l'elaborazione dei dati

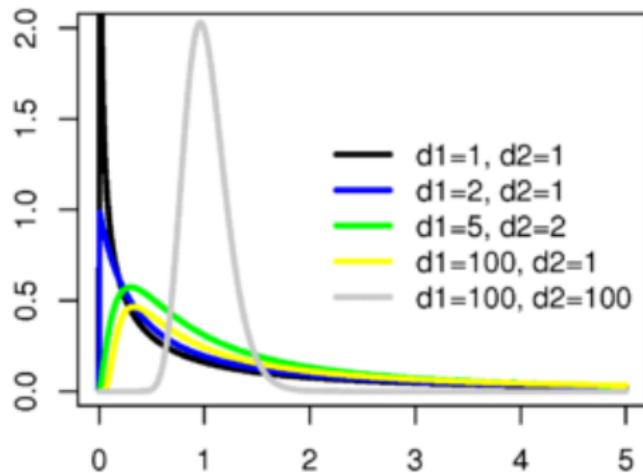
Test di Fisher F-test: test della varianza

Due gaussiane, σ_1^2 è compatibile con σ_2^2 ?

Prendiamo il rapporto tra gli stimatori delle varianze osservate:

$$F = \frac{V_1}{V_2} \quad V = \sum_i \frac{(x_i - \bar{x})^2}{N - 1}$$

segue la distribuzione di Fisher di parametri $F(d1 = n - 1, d2 = m - 1)$



Distribuzione di Fisher

$$f(x; d_1, d_2) = \frac{1}{B(\frac{d_1}{2}, \frac{d_2}{2})} \left(\frac{d_1}{d_2}\right)^{\frac{d_1}{2}} x^{d_1/2 - 1} (1 + \frac{d_1}{d_2}x)^{-(d_1+d_2)/2}$$

per $x > 0$, con B =funzione beta e d_1 e d_2 gradi di libertà della distribuzione $x = \frac{X_1/d_1}{X_2/d_2}$ con X_1 e X_2 variabili aleatorie che seguono una distribuzione di χ^2 con gradi di libertà d_1 e d_2 rispettivamente.

Analisi della varianza (sociologia)

Alcune caratteristiche dip dal gruppo in cui studiate?

Suddivido in gruppi il campione e guardo dati nel gruppo e tra i gruppi

- La più importante applicazione del test di Fisher consiste nell'analisi della varianza (ANOVA, Analysis of Variance)
- Nelle scienze sociali l'analisi della varianza si usa per studiare caratteristiche simili in gruppi diversi
- Confronta G campioni confrontando la varianza interna ai gruppi con la varianza tra i gruppi
- Ipotesi nulla prevede che tutti i campioni provengano dalla stessa popolazione
- Test su G campioni sono compatibili con avere lo stesso valore atteso, nell'ipotesi di normalità con σ fissata ma non nota. Il test è utile in particolare per sapere se il valore atteso di una variabile x possa dipendere da una variabile categoriale in base alla quale è possibile suddividere il campione.

Analisi della varianza

- Si calcola la varianza tra i gruppi $\sigma_{\text{between groups}}^2$ e la varianza interna ai gruppi $\sigma_{\text{within groups}}^2$

$$\sigma_{\text{between groups}}^2 = \sum_{i=1}^G (\bar{x}_i - \bar{x})^2 \frac{n_i}{n-1}$$

G → n° gruppi → val medio tot campione

$$\sigma_{\text{within groups}}^2 = \frac{1}{n-1} \sum_{i=1}^G \sum_{j=1}^{n_i} (x_{ij} - \bar{x}_g)^2 = \sum_{i=1}^G \sigma_g^2 \frac{n_i - 1}{n-1}$$

all'interno calcolo varianza

Statistica del test:

$$t = \frac{(\sigma_{\text{between groups}}^2(n-1)/(G-1))}{(\sigma_{\text{within groups}}^2(n-1)/(n-G))}$$

da confrontare con la distribuzione di Fisher di parametri $F(G-1, n-G)$

Test di bontà del fit (test non parametrici)

- Sono un'importante tipo di test d'ipotesi
- Si ha un campione di dati e una distribuzione e la domanda che ci si pone è: quanto un campione di dati è descritto da una certa pdf?
→ funzione che si accorda ai dati
- I test di bontà del fit confrontano i dati sperimentali con la pdf associata all'ipotesi nulla (oppure confrontano due set di dati sperimentali)
- Ipotesi H_0 : i dati seguono la funzione ipotizzata e le differenze sono solo fluttuazioni
- Si costruisce anche in questo caso un test statistico es χ^2 e likelihood
- Si calcola la probabilità di ottenere un valore del test statistico almeno grande quanto quello misurato, cioè di ottenere dati almeno compatibili con l'ipotesi come quelli misurati o compatibilità minore
- I test che vedremo hanno il vantaggio che sono indipendenti dal tipo di distribuzione (il test è lo stesso sia che i dati seguano per esempio una gaussiana o una distribuzione lineare)

Test di bontà del fit

Se mi chiedo: dati seguono un exp (non sene fit)? con che parametro? (sene fit)

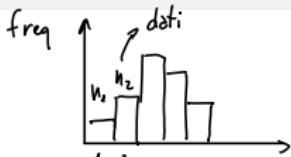
- Il nome “test di bontà del fit” è una classificazione fuorviante: potrebbero anche non avere a che fare direttamente con una procedura di fit
- I test di bontà del fit confrontano la distribuzione dei dati sperimentali con la pdf associata all’ipotesi nulla (oppure confrontano due set di dati sperimentali)
- Della pdf associata potrebbero essere noti a priori tutti i parametri
- Nel caso in cui non fossero noti (e l’ipotesi nulla non specificasse tali parametri), per alcuni test di bontà del fit è possibile determinarli dai dati, per esempio utilizzando una procedura di fit
- In questo caso se il test statistico segue una certa di distribuzione (a seconda del test statistico) a ndf numero di gradi di libertà, seguirà la stessa distribuzione a $ndf - r$ dove r è il numero di parametri determinati direttamente dai dati/fit

Test binned e unbinned

perdo info dentro
di bin (se bin troppo
rispetto risoluzione dati)

- Combinando gli eventi in bin di histogrammi, abbiamo già visto che si perde informazione sui nostri dati
- La scelta di un binning implica infatti necessariamente perdita di informazioni e arbitrarietà nella scelta del binning
- La perdita di informazione sarà trascurabile se la larghezza del bin è piccola rispetto alla risoluzione sperimentale
- Ma in generale, i test binned hanno un potere inferiore rispetto ai test unbinned.
- Per alcuni test binnati è inoltre importante che il numero di eventi per bin sia sufficientemente grande da giustificare alcune assunzioni fatte

Test binnati



Modello teorico : nel bin i -esimo ν_i ; conteggi

Ho misurato n_i nel bin i

N° tot eventi fissato \rightarrow Binomiale

- Supponiamo che il set di dati misurati sia un set di numeri che possiamo rappresentare con un istogramma (conteggi)
- cioè abbiamo ottenuto un set di numeri $\mathbf{n} = (n_1, \dots, n_n)$ con cui posso riempire un istogramma
- $\mathbf{n} = (n_1, \dots, n_n)$ sono il numero di entries per ognuno dei bin dell'istogramma
- Voglio testare un'ipotesi che predice dei valori attesi in ogni bin dell'istogramma $\boldsymbol{\nu} = (\nu_1, \dots, \nu_n)$ es. exp negativo
- Test statistico che mi permette di confrontare i valori osservati in ogni bin dell'istogramma con i valori predetti da un certo modello/teoria (confronto una distribuzione osservata con una attesa)



Consideriamo tre casi: i indice del bin, N n° bin totali

- 1) • Se $n_{tot} = \sum n_i$ è fissato la probabilità in ogni bin è descritta da una multinomiale: $\mathbf{n} \sim Multinomiale(n_{tot}, \mathbf{p})$ con $n_{tot} = \sum_i n_i$ e $\mathbf{p} = \mathbf{n}/n_{tot}$ ($p_i = \nu_i/n_{tot}$)

$$P(\mathbf{n}|\nu) = \frac{n_{tot}!}{n_1! \dots n_N!} p_1^{n_1} \dots p_N^{n_N}$$

- 2) • $n_i \sim Poisson(\nu_i)$, bin indipendenti (ogni conteggio dei bin è distrib secondo Poisson)

- ν_i valore atteso (valore medio di eventi per intervallo di tempo)

- n_i numero di eventi misurati in intervallo di tempo nel bin

$$P(\mathbf{n}|\nu) = \prod_{i=1}^N \frac{\nu_i^{n_i}}{n_i!} e^{-\nu_i}$$

vettore delle freq misurate ↓
misurate valore atteso fra tutte le freq (teorico)

Distrib Poisson

- lo stimatore media dei valori misurati n_i è privo di bias e stima ν_i correttamente

- 3) • Il numero di entries in ogni bin dell'istogramma è sufficientemente grande e bin indipendenti: $n_i \sim Gauss(\nu_i, \sigma_i)$ (di solito se $\nu_i > 100^0$ si usa Gaussiana)

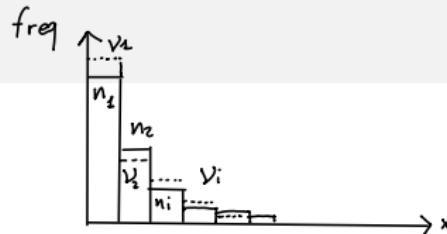
$$p(\mathbf{n}|\nu) = \prod_{i=1}^N \frac{1}{\sqrt{2\pi}\sigma_i} e^{-(n_i - \nu_i)^2/2\sigma_i^2}$$

Statistica di χ^2 di Pearson

1) Statistica di χ^2 di Pearson:

N bin

$$\chi^2 = \sum_{i=1}^N \frac{(n_i - \nu_i)^2}{\sigma_i^2}$$



dove

$$\sigma_i^2 = V(\nu_i)$$

$\underbrace{\nu_i}_{\text{sotto } H_0}$ valore atteso

χ^2 è la somma dei quadrati delle deviazioni del numero di entries misurate nel bin i-esimo dal valor medio atteso nel bin i-esimo divise per la varianza teorica

2) Statistica di χ^2 di Neyman:

N bin

$$\chi^2 = \sum_{i=1}^N \frac{(n_i - \nu_i)^2}{\sigma_i^2}$$

dove

$$\sigma_i^2 = V(n_i)$$

varianza eventi misurati

χ^2 è la somma dei quadrati delle deviazioni del numero di entries misurate nel bin i-esimo dal valor medio atteso nel bin i-esimo divise per la varianza teorica

Ai fini del test non importa il metodo usato

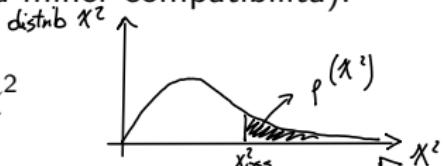
Statistica di χ^2 di Pearson

ottenuto delle formule di prima su un
histogramma

Si può calcolare un p-value tenendo conto che $\chi^2 \geq \chi^2_{\text{oss}}$ definisce la regione a "uguale o minore compatibilità" (χ^2 elevato significa minor compatibilità):

densità di prob

$$p(\chi^2) = \int_{\chi^2_{\text{oss}}}^{+\infty} f(\chi^2) d\chi^2$$



dove $f(\chi^2)$ = pdf della statistica di test sotto l'ipotesi che stiamo testando

- Se le misure n_i sono distribuite secondo una Gaussiana: il χ^2 di Pearson segue la distribuzione di χ^2 con N gradi di libertà
- Se r parametri fossero determinati dai dati/fit seguirebbe la distribuzione di χ^2 con $N-r$ gradi di libertà

caso in cui dono anche ricavare i parametri della pdf

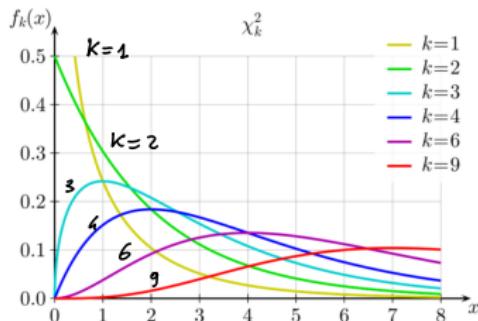
Distribuzione di χ^2

distribuzione di prob della somma
aleatorie al quadrato
di variabili
 \uparrow
(normali e
indipendenti)

variabile aleatoria chi quadro
ndf $\chi_k^2 = x_1^2 + \dots + x_k^2$
var aleatorie

$$f_{\chi^2}(\chi^2, \text{ndf}) = \frac{1}{2^{\text{ndf}/2} \Gamma(\text{ndf}/2)} ((\chi^2)^{\text{ndf}/2 - 1}) e^{-\chi^2/2} \quad \text{dove } \Gamma(x) = \int_0^{+\infty} e^{-t} t^{x-1} dt$$

funzione densità
di probabilità



- La distribuzione ha valor medio $E[\chi^2] = \text{ndf}$ e varianza $V[\chi^2] = 2\text{ndf}$
- Spesso si riporta il χ^2 diviso i gradi di libertà come stima della bontà dell'accordo dati/valori aspettati

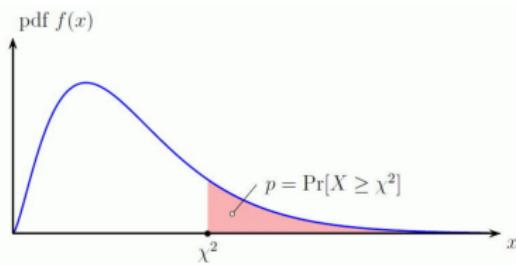
$\frac{\chi^2}{\text{ndf}} \approx 1$ Lab 1
 Meglio usare p-value
 → dati in accordo con modello H_0

χ²

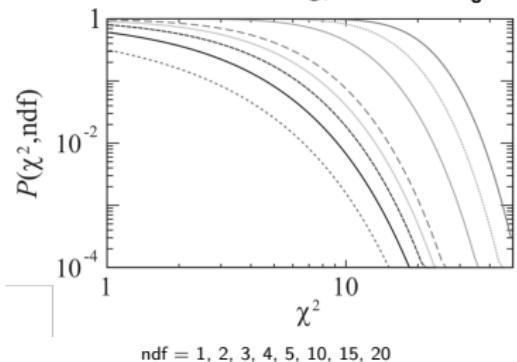
- In realtà è preferibile utilizzare il p-value
 - La probabilità di χ^2 misura la probabilità che, data l'ipotesi nulla, un set di misure fornisce un χ^2 elevato quanto, o più elevato di quello ottenuto (set di dati in disaccordo con H_0)
o più in disaccordo

$$P(\chi^2) = \int_{\chi^2}^{+\infty} f_{\chi^2}(z) dz$$

- Un valore piccolo del p-value: cattivo accordo dei dati con l'ipotesi testata → perché una trova in regione critica di rispetto H_0
 - $\chi^2 = \text{TF1::GetChisquare}()$ $ndf = \text{TF1::GetNDF}()$ $p = \text{TF1::GetProb}()$



$$\begin{array}{lll} \chi^2 = 15 & N = 10 & p = 0.13 \\ \chi^2 = 150 & N = 100 & p = 9 \times 10^{-4} \end{array}$$



Lo stesso valore di χ^2/N corrisponde a p -value molto diversi al variare di N !

Test del Chi-Quadro (generale)

$$\text{variabile di test } \chi^2 = \sum_{i=1}^k \frac{(o_i - v_i)^2}{v_i}$$

k misure ossurate di un evento $\{o_i\}_{i=1 \dots k}$

K misure attese dell'evento $\{v_i\}$

$\{o_i\}$ in accordo con H_0 ? che dice che o_i sono eventi che si discostano da $\{v_i\}$ solo per il caso

χ^2 per k fissato si distribuisce come χ^2 con $\text{ndf} = k - 1$

χ^2 per k variabile aleatoria (es è una Poissoniana dovuta a conteggi) si distribuisce come χ^2 con $\text{ndf} = k$

- χ^2 funziona se nessun valore si presenta con freq < 5

Nel caso usare altri test come Fisher

Statistica di χ^2 di Pearson per Poisson (2) (errore teorico)

- Se le misure n_i sono distribuite secondo Poisson allora

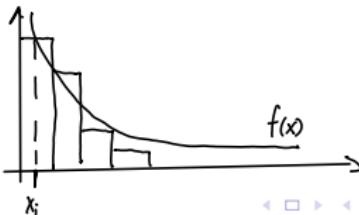
$$\chi^2 = \sum_{i=1}^N \frac{(n_i - \nu_i)^2}{\nu_i}$$

poiché $\sigma_i = \sqrt{\nu_i}$
↓ metodo migliore è integrale di pdf tra x_{\min}^{bin} x_{\max}^{bin}

Il χ^2 di Pearson segue la distribuzione di χ^2 con N gradi di libertà se tutti i ν_i sono abbastanza grandi perché la distribuzione poissoniana sia approssimabile da una distribuzione gaussiana (in pratica $\nu_i \geq 5$ è sufficiente).

- Stesso discorso precedente nel caso r parametri fossero determinati da dati/fit ($N - r$ gradi di libertà)

(NB) $f(x)$ in x_i (centro bin) mi da il
valore medio ν_i .
L'altezza del bin fluttua attorno a ν_i
secondo una Poissoniana



χ^2 per multinomiale (1)

Pearson

- Se $n_{tot} = \sum n_i$ è fissato (non distribuito Poissonianamente), il test controlla solo la forma della distribuzione e non la normalizzazione totale
- la probabilità in ogni bin è descritta dalla multinomiale: $n_i = p_i n_{tot}$ dove p_i è la probabilità per un evento di essere misurato nel bin i secondo l'ipotesi nulla
- In questo caso il test statistico del χ^2 di Pearson

$$\chi^2 = \sum_{i=1}^N \frac{(n_i - p_i n_{tot})^2}{p_i n_{tot}}$$

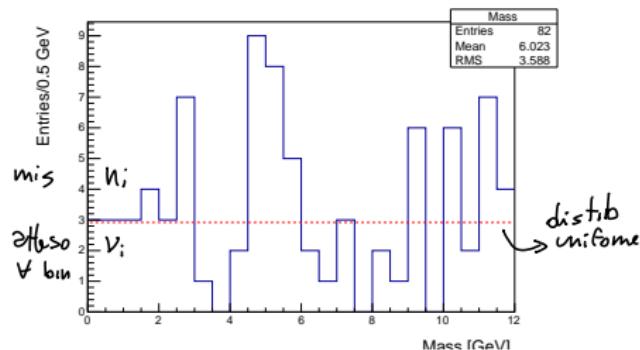
- Da notare che il denominatore non è la varianza $V[n_i] = n_{tot} p_i (1 - p_i)$
- Se tutti $p_i n_{tot} \gg 1$ allora la distribuzione di χ^2 segue la distribuzione di χ^2 per $N - 1$ gradi di libertà.
- Se r parametri fossero determinati da dati/fit seguirebbe la distribuzione di χ^2 per $N - 1 - r$ gradi di libertà

χ^2 di Pearson: esempio

- Supponiamo di avere un leggero eccesso di eventi (conteggi) su un fondo noto a priori
- Supponiamo di considerare $n_i \sim Poisson(\nu_i)$
- Calcoliamo la statistica di test:

$$\chi^2 = \sum_{i=1}^N \frac{(n_i - \nu_i)^2}{\nu_i} \approx \text{var. teorica}$$

- Ora vorremmo calcolare il p-value



- Ma il numero di eventi in molti bins è piccolo (non è soddisfatta la condizione $\nu_i \geq 5$) per cui ci aspettiamo che il χ^2 non segua la distribuzione di χ^2 (~~non segue~~ ^{distr χ^2})
- Non si avrà più una distribuzione della variabile in esame che segue quella del χ^2 con N gradi di libertà
- Tuttavia il χ^2 di Pearson resta un test statistico valido, semplicemente non conosciamo la distribuzione e non so calcolare p-value

χ^2 Se non conosco la sua distribuzione (es $\nu_i < 5$)

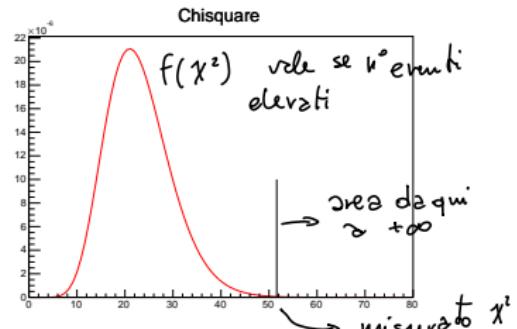
χ^2 di Pearson non segue distr χ^2

- Si può calcolare la distribuzione di χ^2 con metodi Montecarlo

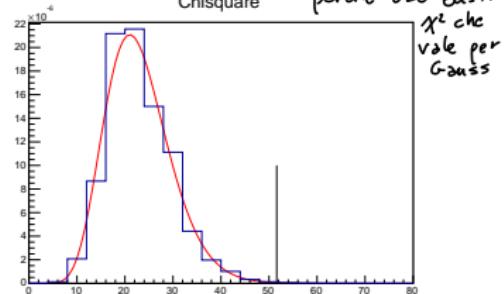
- Si generano le n_i poissoniane con valore medio ν_i
- Si calcola il χ^2
- Si ripete il processo N volte fino ad ottenere una distribuzione del χ^2 dal MonteCarlo
- Si integra la distribuzione per ottenere il p-value

Costruisco con montecarlo dist χ^2

\Rightarrow 1° processo 1 val $\chi^2 \Rightarrow N$ volte \Rightarrow dist $\chi^2 \Rightarrow$ χ^2 in bin



$p = 0.00056 \rightarrow$ errore
perché uso distribuzione



$p = 0.0007 \rightarrow$ corretto

Ipotesi H_0 (distribuzione uniforme) esclusa al %

Binned Likelihood (Likelihood χ^2)

- Per test di bontà di adattamento per istogrammi possiamo anche usare la distribuzione nota di eventi in un bin (nel caso in cui non sia Gaussiana)
 - Poisson: se i contenuti del bin sono indipendenti (non c'e' vincolo sul numero totale di eventi, il numero totale di eventi non è fissato)
 - Multinomiale: se il numero totale di eventi dell'istogramma è fissato
- La statistica di test sarà data dal rapporto:
$$\Rightarrow \lambda = \frac{\prod L(n_i; \nu_i)}{\prod L(n_i; n_i)} \xrightarrow{\text{Likelihood}} \text{Likelihood saturato} \quad \text{error slide}$$

$$\lambda = \frac{L(n_i, \nu_i)}{L(n_i, n_i)} \quad \begin{matrix} \text{vedi riassunto in} \\ \text{fondo per funzioni L} \end{matrix}$$

usando l'approssimazione proposta da Baker-Cousin (modello saturato) dividendo per il valore della likelihood per cui $n_i = \nu_i$
- Per il teorema di Wilks, il rapporto delle likelihood, si comporta come una distribuzione di χ^2 ($\chi^2_\lambda = -2\ln\lambda$) con numero di gradi di libertà uguale a
 - 1) $N - r$ dove N è il numero di bin dell'istogramma, r numero di parametri da stimare sui dati nel caso di dati distribuiti secondo una Poissoniana e
 - 2) $N - r - 1$ nel caso di dati distribuiti secondo una Multinomiale
- Per cui si può usare la distribuzione di χ^2_λ per determinare un p-value che fornisce una misura di bontà del fit (come già discusso nella situazione in cui l'approssimazione Gaussiana è valida).

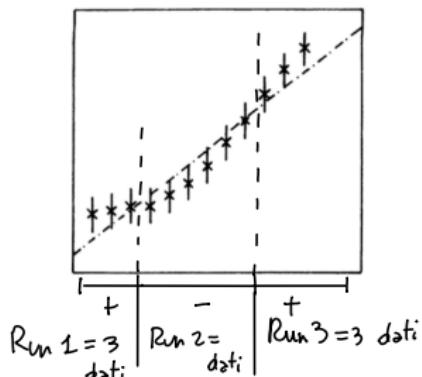
Run test Complementare al χ^2

- Il test di χ^2 è insensibile al segno delle deviazioni
- Un test complementare al test del χ^2 che si basa sul segno delle deviazioni: Run test
- H_0 =tutti i pattern di segno hanno uguale probabilità (se spostamento dal fit è dovuto al caso)
- Chiamiamo N_+ il numero di deviazioni positive e N_- il numero di deviazioni negative e R il numero di run, cioè una sequenza di bin consecutivi dove i dati mostrano deviazioni dello stesso segno (positivo/negativo) H_0 dice che N_+ & N_- distribuiti uniformemente
- Il valore di aspettazione e la varianza di R sono dati:
 $E[R] = 1 + \frac{2N_+N_-}{N_++N_-}$ n° run attesi \hookrightarrow n° di Run, n° di pattern a spost pos o negativo
 $V[R] = \frac{2N_+N_-(2N_+N_- - N_+ - N_-)}{(N_++N_-)^2(N_++N_- - 1)} = \frac{(E[R]-1)(E[R]-2)}{N-1}$
- Il numero di run può essere approssimato da una distribuzione gaussiana per cui la significanza della deviazione di un numero di runs r osservato dal valore atteso è

$$Z = \frac{r - E[R]}{\sqrt{V[R]}}$$

Run test (esempio)

- Dal test del χ^2 fit ok... *p-value accettabile*
- Proviamo ad applicare il Run test che fornisce un'informazione aggiuntiva rispetto al test di χ^2



n^o di dati \rightarrow $+++ \dots + +$ \nearrow $N = N_+ + N_- = 12$ e $N_+ = 6$ e $N_- = 6 \rightarrow$ spost pos neg
2 "+" runs e 1 "-" run

Per cui se calcolo:

$$E[R] = 1 + \frac{2N_+ N_-}{N}$$

$$V(R) = 2N_+ N_- \frac{(2N_+ N_- - N)}{N^2(N-1)}$$

Ottengo:

$$E[R] = 7 \text{ e } V[R] = 2.73 \rightarrow \text{mi aspetto} \geq 7 \text{ run}$$

$$Z = \frac{r - E[R]}{\sqrt{V[R]}} = \frac{7 - 3}{\sqrt{2.73}} = 2.4\sigma \text{ che equivale ad una significatività dell'1%}$$

se soglia scelta all'1%

Ipotesi nulla rigettata: fit non buono! ↵

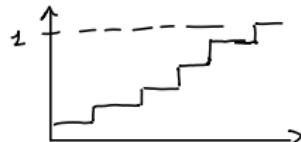
Usare se scostamenti dal fit non sono random

Test unbinned

non perdo info coi bin, idea base di tutti gli unbinned usano statistiche d'ordine \rightarrow criterio che ordina i dati (decrescente)

- Abbiamo N osservazioni indipendenti: x_1, \dots, x_N della variabile aleatoria x
- Riordiniamo le osservazioni in ordine crescente per cui $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(N)}$
- Le osservazioni ordinate $x_{(i)}$ sono chiamate statistica d'ordine
- Si scrive la distribuzione cumulativa empirica $S_N(x)$ per N misure come

$$S_N(x) = \begin{cases} 0 & x < x_{(1)} \\ i/N & x_{(i)} \leq x < x_{i+1}, i = 1, \dots, N-1 \\ 1 & x_n \leq x \end{cases}$$

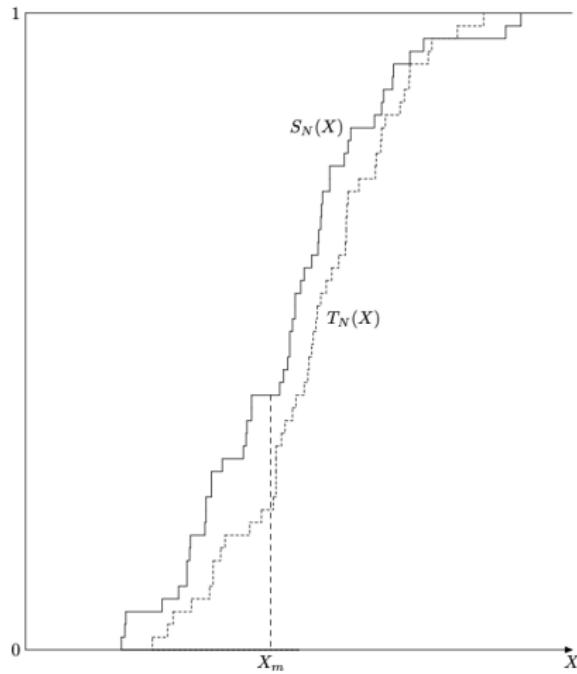


$S_N(x)$ per set dati x
 $T_N(x)$ per set dati y } confronto

Test unbinned

- I test unbinned utilizzando si basano sul confronto tra la distribuzione cumulativa della distribuzione di probabilità $F(x) = \int_{-\infty}^x f(x')dx'$ sotto l'ipotesi H_0 con l'equivalente distribuzione dei dati $S_N(x)$
- La statistica di test utilizza una qualche differenza tra la distribuzione cumulativa sperimentale e l'ipotetica distribuzione cumulativa: $S_N(x) - F(x)$ cioè misura la “distanza” tra le due funzioni cumulative
- Analogamente nel caso di confronto tra due distribuzioni sperimentali si può utilizzare $S_N(x) - T_N(x)$ dove $T_N(x)$ è la distribuzione cumulativa empirica di un campione di dati

Test unbinned: statistica ordinata



- In questo esempio, la distanza massima $S_N(x) - T_N(x)$ avviene a $x = x_m$
- A seconda di come si misura la “distanza” tra le due funzioni cumulative si hanno diversi tipi di test

Kolmogorov-Smirnov test

- Utilizza la deviazione massima tra la distribuzione osservata $S_N(x)$ e la distribuzione $F(x)$ attesa sotto l'ipotesi H_0
- È definita come: *Massima distanza con*
$$D_n = \max |S_n(x) - F(x)|$$
 o senso segno

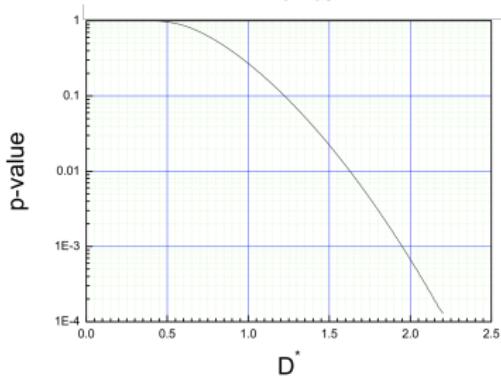
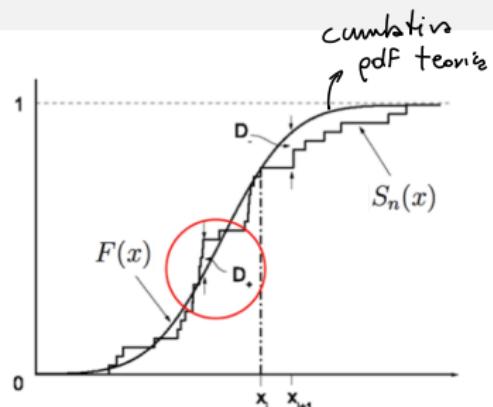
$$D_n^{\pm} = \max \{ \pm |S_n(x) - F(x)| \}$$

quando si considera test one-side

significato

Test size α	Critical value of $\sqrt{N}D_N$
0.01	1.63
0.05	1.36
0.10	1.22
0.20	1.07

- Al 5%, il valore critico è $D = \frac{1.36}{\sqrt{N}}$ dove N è il numero di misure
- l'ipotesi nulla non è rigettata se $D < D_{\text{crit}}$



$$D^* = \sqrt{ND}$$

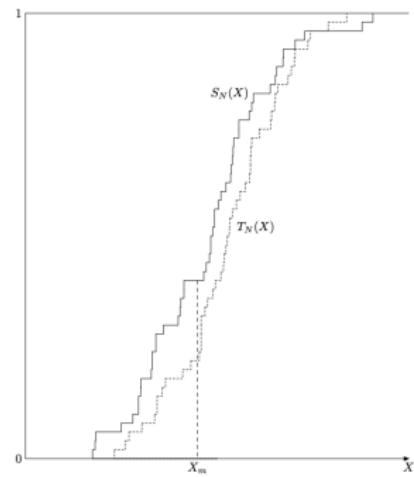
Kolmogorov-Smirnov test: 2 campioni

- Il test di KS può essere anche utilizzato per confrontare due campioni di dati (x_1, \dots, x_n) e (y_1, \dots, y_n) per verificare l'ipotesi che entrambi i campioni provengano dalla stessa distribuzione
- L'equivalente statistica per confrontare due distribuzioni cumulative empiriche $S_N(x)$ e $T_N(x)$ è:

$$D_{ST} = \max |S_N(x) - T_N(x)|$$

$$D_{ST}^{\pm} = \max \{ \pm [S_N(x) - T_N(x)] \}$$

per il test one-side



Kolmogorov-Smirnov test: osservazioni

N dimensioni come ordino? Non banale

- I test unbinned basandosi sulla statistica d'ordine (per cui una distribuzione ha dei valori ordinabili secondo un qualche criterio), non sono facilmente estendibili a N dimensioni per cui sono applicabili a dati che dipendono da un'unica variabile aleatoria
- Se alcuni parametri della distribuzione $f(x)$ sono determinati dal campione di dati x_1, \dots, x_n (i.e. procedura di fit), il test non può essere applicato (non c'è un qualcosa di equivalente al numero di gradi di libertà come nel caso del test di χ^2)
- Ha d'altra parte tutti i vantaggi di un test unbinned: più potente rispetto ai test binned, possibile effettuarlo anche con un numero piccolo di dati

Se parametri noti a priori \Rightarrow k-s banale

altrimenti no perché cambia rapporto $\propto \sqrt{N} D_N$ e devo fare montecarlo
Non c'è il modo di ricalcolare k-s come faccio $\frac{\chi^2_{\text{ndf}}}{\chi^2_{\text{ndf}}} \xrightarrow{\text{montecarlo}} \sqrt{N} D$

Likelihood unbinned

- La likelihood unbinned non fornisce strumenti per la bontà del fit (al contrario del χ^2)
- Potremmo pensare che il valore di $-In\mathcal{L}$ possa essere una buona statistica di test per il test di GOF: sappiamo che il massimo della likelihood fornisce la miglior stima dei parametri
- Ma nella stima di maximum likelihood, stiamo usando la likelihood per un set di dati fissi in funzione dei parametri, mentre i test di GOF, usiamo la likelihood per un'ipotesi fissa in funzione dei dati good of fit
- Vedremo un esempio in cui può essere visto facilmente che la likelihood non ha nessun poter come statistica di test per i test di GOF poichè tutti i campioni di dati presi in considerazione avrebbero lo stesso valore di likelihood, indipendentemente da quanto seguono la distribuzione sotto l'ipotesi H_0

Likelihood unbinned ? lv \mathcal{L} su modelli diversi c'è ugual?

Esempio: fit esponenziale (vita media)

$$\mathcal{L}(\lambda, x_1, x_2, \dots, x_n) = \prod_{i=1}^n \lambda e^{-\lambda x_i} = \lambda^n e^{-\lambda \sum x_i}$$

$$\frac{d\mathcal{L}(\lambda, x_1, x_2, \dots, x_n)}{d\lambda} = n\lambda^{n-1} e^{-\lambda \sum x_i} - \sum x_i \lambda^{n-1} e^{-\lambda \sum x_i} = 0$$

$$n - (\sum x_i)\lambda = 0 \quad \rightarrow \lambda = \frac{n}{\sum x_i}$$

Sostituendo ottengo

*Campion slesso n° dati e
valor medio \Rightarrow hoo stesso λ*

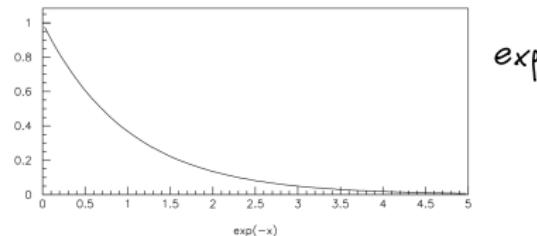
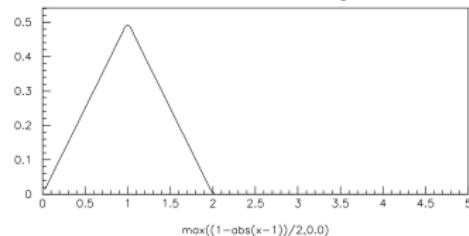
$$\begin{aligned} -2 \ln(\mathcal{L})_{min} &= -2n \ln(\lambda) + 2\lambda \sum x_i \\ &= -2n \ln(\lambda) + 2n = 2n(1 - \ln(\lambda)) = f(n, \lambda) \end{aligned}$$

Siccome $-2 \ln(\mathcal{L})$ è funzione unicamente di n e λ non può essere utilizzata come test di bontà del fit.

Quindi qualunque distribuzione con valor medio λ e stesso numero di eventi n danno lo stesso valore di likelihood

Likelihood unbinned

distrib triangolare



Poichè entrambe le distribuzioni hanno la stessa media forniscono lo stesso valore di $-2 \ln(\mathcal{L})_{\min}$ quando fittate con un'esponenziale.

Tutti i set di dati con stessa media $1/\lambda$ forniscono lo stesso valore di likelihood indipendentemente dalla distribuzione. Per il test di likelihood, significherebbe che entrambe le distribuzioni sono un buon fit con un'esponenziale!

```
Double_t TH1::Chi2Test ( const TH1 * h2,  
                        Option_t * option = "UU",  
                        Double_t * res = 0  
                      ) const
```

virtual

χ^2 test for comparing weighted and unweighted histograms

Se dati provengono dalla stessa distib.

Function: Returns p-value. Other return values are specified by the 3rd parameter

Parameters

[in] **h2** the second histogram

[in] **option**

- "UU" = experiment experiment comparison (unweighted-unweighted)
- "UW" = experiment MC comparison (unweighted-weighted). Note that the first histogram should be unweighted
- "WW" = MC MC comparison (weighted-weighted)
- "NORM" = to be used when one or both of the histograms is scaled but the histogram originally was unweighted
- by default underflows and overflows are not included:
 - "OF" = overflows included
 - "UF" = underflows included
- "P" = print chi2, ndf, p_value, igood
- "CHI2" = returns chi2 instead of p-value
- "CHI2/NDF" = returns χ^2/ndf

[in] **res** not empty - computes normalized residuals and returns them in this array

scipy.stats.ks_2samp

`scipy.stats.ks_2samp(data1, data2)`

[\[source\]](#)

(<http://github.com/scipy/scipy/blob/v0.15.1/scipy/stats/stats.py#L3966>)

Computes the Kolmogorov-Smirnov statistic on 2 samples.

This is a two-sided test for the null hypothesis that 2 independent samples are drawn from the same continuous distribution.

Parameters: `a, b : sequence of 1-D ndarrays`

two arrays of sample observations assumed to be drawn from a continuous distribution, sample sizes can be different

Returns:

`D : float` *valore della statistica*

KS statistic

`p-value : float`

two-tailed p-value

scipy.stats.kstest

```
scipy.stats.kstest(rvs, cdf, args=(), N=20, alternative='two-sided', mode='approx')
(http://github.com/scipy/scipy/blob/v0.14.0/scipy/stats/stats.py#L3307)
```

[source]

Perform the Kolmogorov-Smirnov test for goodness of fit.

This performs a test of the distribution $G(x)$ of an observed random variable against a given distribution $F(x)$. Under the null hypothesis the two distributions are identical, $G(x)=F(x)$. The alternative hypothesis can be either 'two-sided' (default), 'less' or 'greater'. The KS test is only valid for continuous distributions.

Parameters: *rvs* : str, array or callable

If a string, it should be the name of a distribution in `scipy.stats` (`./stats.html#module-scipy.stats`). If an array, it should be a 1-D array of observations of random variables. If a callable, it should be a function to generate random variables; it is required to have a keyword argument `size`.

cdf : str or callable

If a string, it should be the name of a distribution in `scipy.stats` (`./stats.html#module-scipy.stats`). If *rvs* is a string then *cdf* can be False or the same as *rvs*. If a callable, that callable is used to calculate the cdf.

args : tuple, sequence, optional

Distribution parameters, used if *rvs* or *cdf* are strings.

N : int, optional

Sample size if *rvs* is string or callable. Default is 20.

alternative : {'two-sided', 'less', 'greater'}, optional

Defines the alternative hypothesis (see explanation above). Default is 'two-sided'.

mode : 'approx' (default) or 'asymp', optional

Defines the distribution used for calculating the p-value.

- 'approx' : use approximation to exact distribution of test statistic
- 'asymp' : use asymptotic distribution of test statistic

Returns: *D* : float

KS test statistic, either D, D+ or D-.

p-value : float

One-tailed or two-tailed p-value.

Riassunto GOF test: Binned

Dipendono dall'arbitrarietà del binning

- χ^2 :
 - I dati devono essere distribuiti gaussianamente in ciascun bin (applicabile se il numero di eventi per ogni bin è maggiore di 5)
 - Segue la distribuzione di χ^2 con $ndf = N$ gradi di libertà per la Poissoniana e $ndf = N-1$ per la multinomiale ($N = \text{numero di bin dell'istogramma}$)
 - Se la distribuzione dipende da r parametri da stimare sui dati: $\sim \chi^2(ndf - r)$
- Likelihood binnata ($\chi^2 = -2\ln\mathcal{L}$) $\chi^2_{\text{poisson}} = 2 \sum_i \nu_i - n_i + n_i \ln(n_i/\nu_i)$ Likelihood
 - I dati non devono essere distribuiti gaussianamente in ciascun bin (minori di 5)
 - distribuiti Poissonianamente se il contenuto dei bin è indipendente (no vincoli sul numero totale di eventi)
 - distribuiti secondo una Multinomiale (se il numero totale degli eventi nell'istogramma è fissato) $\chi^2_{\text{multi}} = 2 \sum_i n_i \ln(n_i/\nu_i)$ Likelihood
- Per numero di eventi piccoli è sempre comunque consigliato utilizzare un metodo MC per ottenere la distribuzione di χ^2

Riassunto GOF test: Unbinned

- Kolmogorov-Smirnov test
 - Unbinned
 - Funziona anche con numeri piccoli di eventi
 - Implementazioni disponibili standard solo per distribuzioni continue (non discrete) [anche se il test è estendibile a distribuzioni discrete]
 - Non applicabile quando i parametri della distribuzione sono stimati dal campione di dati (è necessario modificare i valori critici D_{crit} , necessario MonteCarlo))
- Likelihood non binnata: non fornisce GoF intrinseca

Riassunto sui metodi di fit (GOF)

- χ^2 :
 - GOF ok
 - Dipende dal binning
 - I dati devono essere distribuiti gaussianamente in ciascun bin (applicabile se i dati per ogni bin sono maggiori di 5)
- Likelihood binnata:
 - GOF ok (χ^2 modificato)
 - Dipende dal binning
 - I dati non devono essere per forza distribuiti gaussianamente in ciascun bin (minori di 5)
- Likelihood non binnata
 - Molto più performante, non richiede che i dati siano binnati
 - No GOF intrinseca
 - I dati devono essere binnati per confrontarli con la funzione

La Likelihood in generale non fornisce strumenti per la bontà del fit (al contrario del χ^2)